Instituto Nacional de Astrofísica, Óptica y Electrónica

Departamento de Ciencias Computacionales

Procesamiento de Señal Hablada

Práctica de Laboratorio

Presenta:

Ashley Dafne Aguilar Salinas

Docentes:

Dr. Carlos Alberto Reyes García

Dr. Alejandro Antonio Torres García

8 de abril de 2026

Práctica de Laboratorio

Procesamiento de Señal Hablada

Ashley Dafne Aguilar Salinas[1,†]

[1] *Instituto Nacional de Astrofísica, Óptica y Electrónica. Departamento de Ciencias Computacionales*

Abril 8, 2026

E-mail address: ashleyd.aguilars@inaoep.mx
CC BY 4.0

Introducción

El análisis acústico de la voz es una herramienta fundamental en el procesamiento de bioseñales que permite cuantificar de manera objetiva las propiedades físicas del habla. Mediante la transformación de la señal acústica en parámetros numéricos, es posible estudiar la relación entre la biomecánica de los pliegues vocales y la configuración del tracto vocal. Esta disciplina no solo facilita la caracterización de la señal sonora, sino que también proporciona una base técnica para aplicaciones en ingeniería que requieren precisión en el reconocimiento de patrones y la síntesis de voz (Droguett G., 2017).

En el caso de las voces femeninas en la etapa de adultez temprana, comprendida entre los 20 y 30 años, la literatura técnica establece rangos específicos para su caracterización. Se ha determinado que la frecuencia fundamental (F_0) para este grupo demográfico presenta un promedio que oscila entre los 190 Hz y 225 Hz (Zraick et al., 2021). Asimismo, debido a las dimensiones anatómicas del tracto vocal femenino, las frecuencias de los formantes tienden a ser más elevadas que en las voces masculinas, lo que exige un ajuste preciso en la tasa de muestreo y en los algoritmos de predicción lineal para evitar la captura de ruido espectral (Teixeira et al., 2022).

En esta práctica se realizó el procesamiento de una señal de voz femenina, empleando los parámetros sugeridos por la literatura para asegurar la fidelidad del análisis. El flujo de trabajo consistió en la segmentación manual de muestras en el software Praat y su posterior análisis automatizado en Python a través de la interfaz `Parselmouth`, la cual permite la integración de algoritmos de procesamiento de voz en entornos de programación (Jadoul et al., 2018). El presente reporte se estructura en tres etapas: primero, la descripción de la metodología de adquisición; segundo, las especificaciones técnicas para la ejecución del software; y finalmente, la presentación de los resultados comparativos y las conclusiones derivadas del estudio.

Metodología

En esta sección se describe el procedimiento para la captura, procesamiento y análisis de las señales de voz. El flujo de trabajo general se presenta en la Figura 1. El proceso se estructuró en tres etapas principales: la adquisición de los audios, la segmentación manual de las muestras y la extracción de parámetros mediante scripts de programación. El objetivo de este procedimiento fue obtener datos cuantitativos que permitan contrastar los resultados obtenidos bajo distintas configuraciones de análisis.

Adquisición y segmentación de la señal

La captura de las señales se realizó utilizando el software Praat, configurando una tasa de muestreo de $8000Hz$ en formato monoaural. Se grabaron diez palabras clave relacionadas con protocolos de emergencia: terremoto, erupción, albergue, código, simulacro, rescate, evacuación, sísmico, réplica y plan. Estas grabaciones se almacenaron inicialmente en archivos de audio extendidos, los cuales se encuentran disponibles en el archivo comprimido `grabaciones_originales.zip`.

Cada palabra fue pronunciada en cinco ocasiones, manteniendo pausas breves entre repeticiones. Posteriormente, se realizó una segmentación manual en el entorno de Praat para identificar los límites temporales de cada emisión. Cada segmento fue extraído y guardado como un archivo individual en formato .wav, generando un total de 50 muestras. Estas muestras segmentadas, organizadas por palabra y repetición, se localizan en el archivo `grabaciones_segmentadas.zip` para su procesamiento posterior.

Procesamiento y extracción de parámetros

El análisis de las 50 muestras segmentadas se automatizó mediante un script de Python utilizando la librería `parselmouth`. Este entorno permitió procesar de manera sistemática cada archivo para extraer los descriptores solicitados: frecuencia fundamental (F_0), intensidad, formantes (F_1 y F_2), coeficientes cepstrales en la escala de Mel (MFCC) y codificación predictiva lineal (LPC).

Se ejecutaron dos ciclos de análisis para contrastar los resultados obtenidos. El primero empleó los valores por defecto del software. El segundo utilizó parámetros ajustados bajo criterios técnicos específicos: se limitó la frecuencia máxima de búsqueda de formantes a 4000 Hz, de acuerdo con el límite de Nyquist para la tasa de muestreo de 8000 Hz, y se estableció el orden del LPC en 10. Los datos resultantes de ambos procesos se consolidaron en archivos de formato `.csv`.

Adicionalmente, se desarrolló un análisis visual automatizado mediante los módulos `espectro.py` y `main_espectro.py`. Estos scripts procesan cada una de las 50 muestras para generar espectrogramas interactivos y gráficas de espectro de potencia (ajustadas hasta una banda pasante efectiva de 4000 Hz). Una vez procesadas, las imágenes correspondientes se estructuran y almacenan temporalmente por palabra, facilitando un diagnóstico cualitativo del contenido fonético.

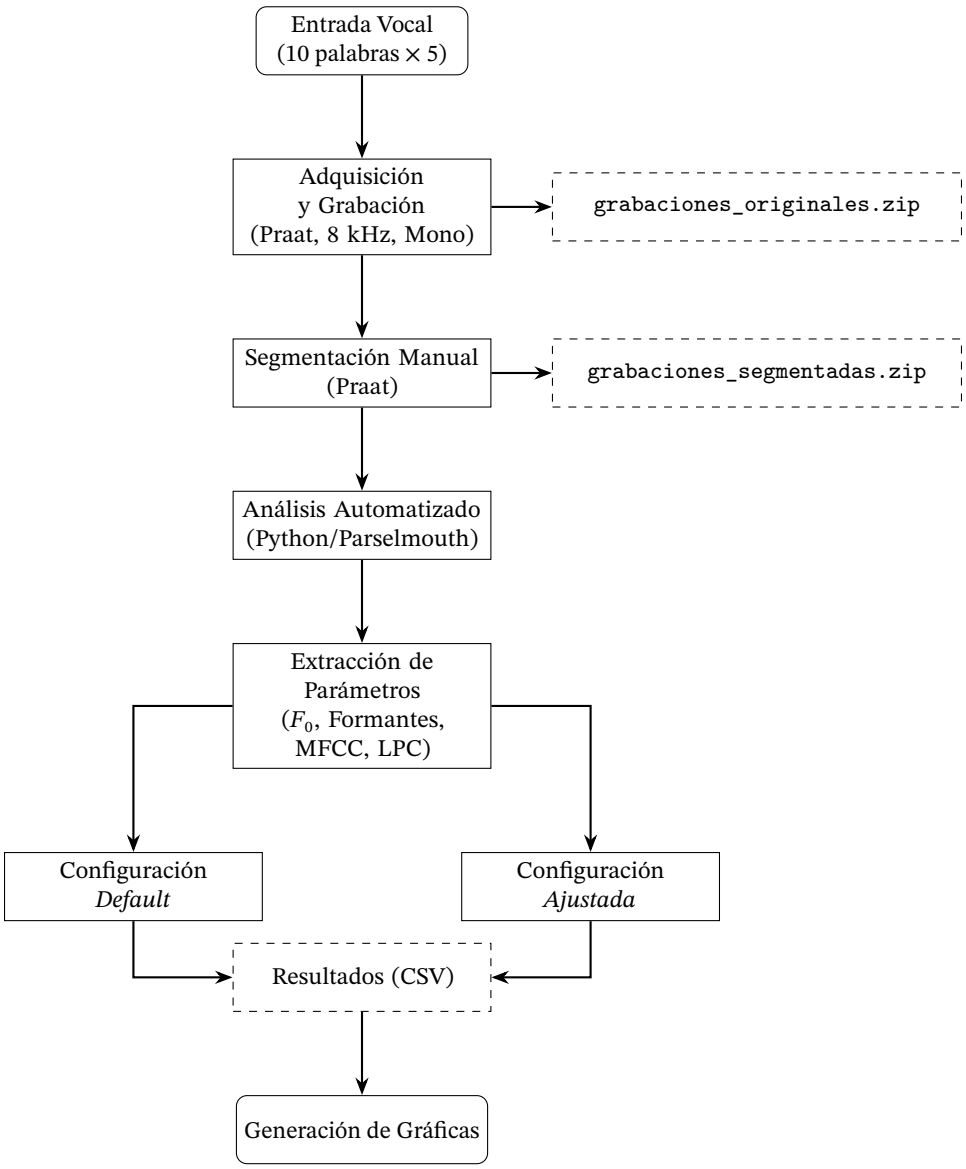

Figure 1. Diagrama de flujo del procesamiento de bioseñales de voz.

Uso del Programa

El proyecto completo, incluyendo el código fuente, archivos de configuración y muestras, se encuentra disponible en el siguiente repositorio: https://github.com/AshleyDafneAguilar/praat_bio.git

Para la ejecución del código se utiliza la herramienta `uv`, un administrador de paquetes de Python de alto rendimiento. El comando `uv run` simplifica el flujo de trabajo al gestionar automáticamente el entorno virtual e instalar las dependencias necesarias (como `parselmouth`, `pandas` y `numpy`) preconfiguradas en el proyecto. Esto garantiza que el análisis se ejecute en un entorno controlado sin necesidad de instalaciones manuales adicionales.

Para iniciar el procesamiento desde la terminal, se utiliza la siguiente sintaxis:

```
uv run main.py <archivo_de_configuracion.ini>
```

Es posible ejecutar el script empleando tanto la configuración principal como la configuración por defecto para contrastar las variaciones en los resultados obtenidos:

```
uv run main.py configuraciones.ini
uv run main.py configuraciones_default.ini
```

Por otro lado, la generación automatizada de los espectrogramas y espectros de potencia (100 imágenes en total) se realiza ejecutando el siguiente comando:

```
uv run main_espectro.py
```

Esta instrucción recorrerá todos los audios segmentados, organizando los archivos visuales de salida en los directorios correspondientes por palabra dentro de `resultados/img`.

Resultados y Discusión

En esta sección se presentan los datos obtenidos tras el procesamiento de las muestras de voz, contrastando las dos configuraciones de análisis empleadas. Los resultados permiten observar cómo la modificación de parámetros técnicos impacta directamente en la precisión de la extracción de bioseñales.

La Figura 2 muestra los promedios generales de las métricas principales. Se observa que mientras el Pitch (F_0) y el primer formante (F_1) mantienen valores similares en ambas pruebas, el segundo formante (F_2) presenta una disminución notable en la configuración ajustada. Esta diferencia se atribuye a que, al limitar la búsqueda a 4000 Hz (frecuencia de Nyquist para audio de 8 kHz), se descartan estimaciones erróneas que el algoritmo por defecto realiza en regiones espectrales carentes de información fonética real.

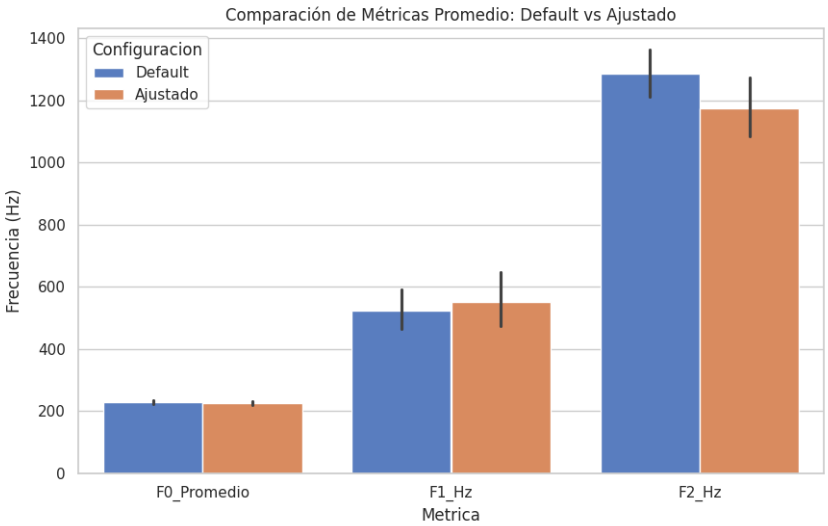

Figure 2. Comparativa de promedios de los niveles de frecuencia de la voz.

El análisis del espacio vocálico representado en la Figura 3 refuerza esta observación. Siguiendo la convención fonética de ejes invertidos, se aprecia que los puntos de la configuración ajustada tienden a agruparse de forma más compacta y consistente. Por el contrario, los resultados obtenidos con los valores por defecto muestran una dispersión mayor, lo que sugiere que el análisis sin restricciones de frecuencia introduce ruido en la identificación de las resonancias del tracto vocal.

Finalmente, la estabilidad del seguimiento de la frecuencia fundamental se analiza en la Figura 4. En este caso, ambas curvas son prácticamente idénticas, lo que demuestra que el rango de búsqueda configurado fue apropiado para las características de la voz grabada. El ajuste del límite superior de frecuencia no alteró los resultados, validando la robustez del algoritmo de Pitch en ambas configuraciones para este conjunto de datos.

Como complemento al análisis macro numérico, los resultados visuales individuales originados tras la ejecución de `main_espectro.py` proporcionaron información valiosa. Las 100 imágenes agrupadas por palabra en las subcarpetas resultantes validaron de forma visual que en los espectrogramas se aprecian armónicos consistentes en rangos similares a los formantes identificados durante la codificación LPC. Dichos gráficos mantuvieron un alto contraste gracias a su normalización adaptada directamente a nivel logarítmico (para prevenir desbordamientos) limitándose en el visualizador a 4000 Hz, lo cual evita observar perturbaciones ininteligibles por encima del tope marcado por el modelo acústico escogido.

Conclusiones

Esta práctica permitió visualizar que el ajuste de los parámetros técnicos, basado en los límites de muestreo de la señal, es fundamental para obtener resultados precisos. Se observó que controlar la frecuencia máxima de los formantes y el orden del LPC corrige las desviaciones de las configuraciones automáticas, logrando una representación más fiel del espacio vocálico.

Asimismo, el uso conjunto de Praat para la segmentación manual y Python para el procesamiento automatizado demostró ser un método eficiente y confiable. Este enfoque asegura que la extracción de métricas como el Pitch y los formantes sea consistente, estableciendo una base técnica sólida para el análisis de bioseñales de voz en condiciones de ancho de banda limitado.

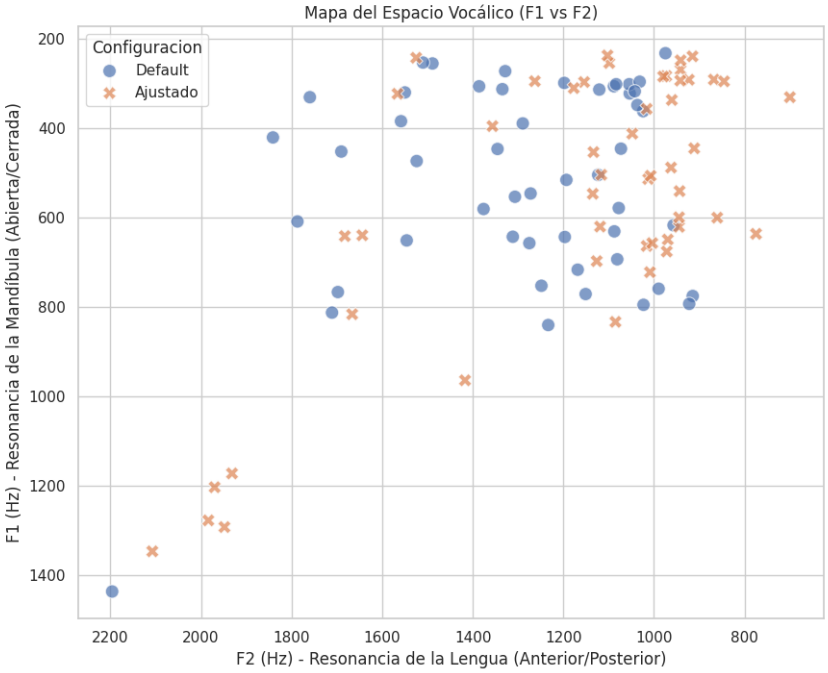

Figure 3. Distribución de formantes en el espacio vocálico F1 vs. F2.

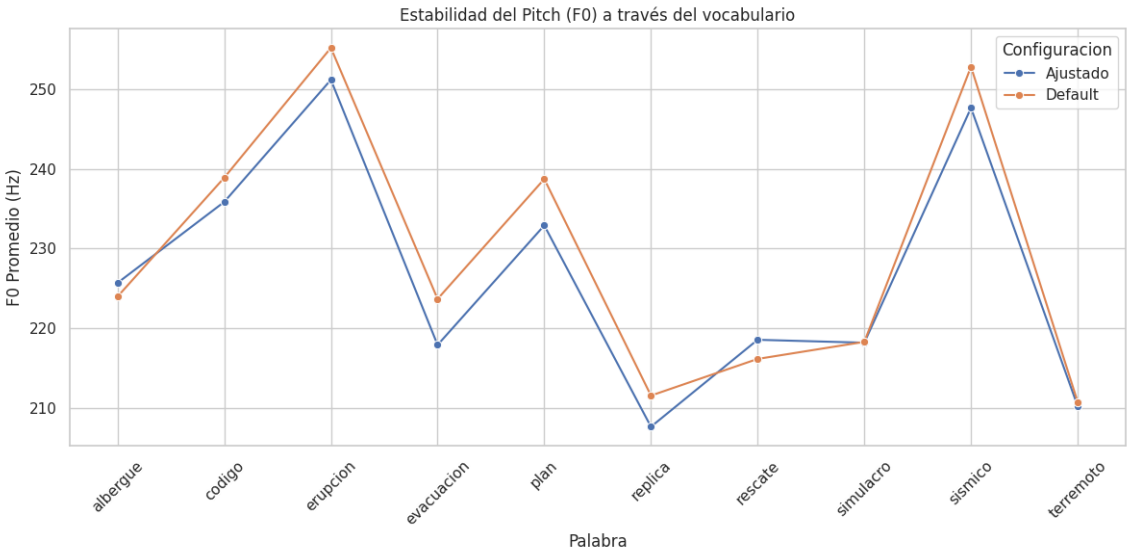

Figure 4. Seguimiento de la frecuencia fundamental por palabra.

Referencias

[1] Jayakumar, T., Benoy, J. J., & Yasin, H. M. (2022). Effect of Age and Gender on Acoustic Voice Quality Index Across Lifespan: A Cross-sectional Study in Indian Population. *Journal of Voice*, 36(3), 436.e1–436.e8. https://doi.org/10.1016/j.jvoice.2020.05.025

[2] Jadoul, Y., Thompson, B., & de Boer, B. (2018). Introducing Parselmouth: A Python interface to Praat. *Journal of Phonetics*, 71, 1–15. https://doi.org/10.1016/j.wocn.2018.07.001

[3] Barmak, E., Altan, E., Söylemez, D., & Çadallı Tatar, E. (2024). Investigation of Acoustic Voice Characteristics of Individuals Diagnosed with Muscle Tension Dysphonia. *Turkish Archives of Otorhinolaryngology*, 62(2), 58–65. https://doi.org/10.4274/tao.2024.2024-3-15

[4] Droguett, Y. G. (2017). Aplicaciones clínicas del análisis acústico de la voz. *Revista de Otorrinolaringología y Cirugía de Cabeza y Cuello*, 77, 474–483. https://doi.org/10.4067/s0718-48162017000400474